


گزارش پروژه اول هوش مصنوعی

پیش بینی هزینه های بیمه پزشکی



فاز اول پروژه پایانی

طراحی و پیاده سازی جامع رگرسیون چندجمله ای، شبکه های عصبی (MLP) و پیاده سازی گام به گام سیستم استنتاج فازی-عصبی تطبیقی (ANFIS).

نام دانشجو: حامد بهروزی مقدم - علی رضا دیوسالار

شماره دانشجویی: ۴۰۲۱۷۴۹۳ - ۴۰۲۱۵۶۳۳

استاد درس: جناب آقای دکتر علیاری

لینک کد پروژه: [Google Colab](#)

لینک دیتاست پروژه: [Kaggle Dataset](#)



فهرست مطالب

۱	مقدمه و تشریح کلی پروژه	۲
۲	پیش‌پردازش و تحلیل اکتشافی داده‌ها (EDA)	۲
۱.۲	بصری‌سازی ساختار داده‌ها و توزیع ویژگی‌ها	۲
۳	فاز اول: رگرسیون خطی و تعاملی (چندجمله‌ای)	۳
۴	فاز دوم: شبکه‌های عصبی (MLP)	۴
۵	فاز سوم: سیستم استنتاج فازی-عصبی تطبیقی (ANFIS)	۵
۱.۵	تشریح ریاضیاتی ۵ لایه شبکه ANFIS	۵
۲.۵	الگوریتم یادگیری هیبریدی (Hybrid Learning Rule)	۷
۳.۵	مدیریت چالش نفرین ابعاد (Curse of Dimensionality)	۷
۶	تحلیل نمودارهای یادگیری و توابع فازی	۸
۷	ارزیابی جامع و نتیجه‌گیری نهایی	۹
۱.۷	تحلیل پدیده اشباع قوانین و برتری رگرسیون	۱۱

۱ مقدمه و تشریح کلی پروژه

هدف مهندسی پروژه

تبیین یک مدل ریاضی و هوشمند با تفسیرپذیری بالا و خطای اندک جهت پیش‌بینی نرخ عددی متغیر پیوسته حق بیمه سالیانه افراد بر اساس الگوهای فیچرهای دموگرافیک.

مسئله تخمین حق بیمه پزشکی به دلیل ماهیت غیرخطی و رفتارهای سینگولار داده‌ها (به طور ویژه جهش ناگهانی هزینه‌ها برای افراد سیگاری با شاخص توده بدنی بالا) یکی از چالش‌های کلاسیک در حوزه یادگیری ماشین به شمار می‌رود. در حوزه‌های حساس مانند پزشکی و بیمه، تنها داشتن یک پیش‌بینی دقیق کافی نیست؛ بلکه **«تفسیرپذیری»** (Interpretability) مدل و توانایی توضیح دلایل پشت هر تصمیم به شدت حائز اهمیت است.

در این پروژه، ما با پیاده‌سازی سه رویکرد کاملاً متمایز شامل مدل‌های آماری خطی تعاملی، شبکه‌های عصبی متراکم (MLP) به عنوان یک جعبه سیاه پیچیده، و در نهایت سیستم‌های تلفیقی عصبی-فازی (ANFIS) به عنوان یک جعبه شیشه‌ای، موازنه میان معیارهای محاسباتی پایداری، دقت پیش‌بینی و قدرت تفسیرپذیری مدل‌ها را به صورت آزمایشگاهی تحلیل می‌نماییم.


۲ پیش‌پردازش و تحلیل اکتشافی داده‌ها (EDA)

مجموعه داده‌های بیمه شامل ۱۳۳۸ رکورد است. برای آماده‌سازی این دیتاست، فرآیندهای مهندسی ویژگی زیر به صورت گام‌به‌گام در یک Pipeline ایمن اعمال شده است:


- کدگذاری متغیرهای دودویی: متغیرهای رشته‌ای نظیر جنسیت (sex) و وضعیت دخانیات (smoker) توسط LabelEncoder به کدهای باینری صفر و یک نگاشت شدند.
- تبدیل متغیرهای چندکلاسه: ویژگی منطقه‌ای (region) با متد One-Hot Encoding بسط یافت و برای ممانعت از هم‌خطی چندگانه (Multicollinearity)، پارامتر drop_first=True اعمال گردید.
- جلوگیری از نشت داده‌ها (Data Leakage): تقسیم‌بندی مجموعه به دو بخش آموزش و تست با نسبت ۸۰ به ۲۰ مستقیماً پیش از فاز مقیاس‌دهی انجام پذیرفت. سپس StandardScaler منحصرراً بر روی داده‌های آموزش fit گردید تا هیچ اطلاعاتی از مجموعه تست وارد فاز آموزش نگردد.

۱.۲ بصری‌سازی ساختار داده‌ها و توزیع ویژگی‌ها


پیش از ورود به فاز مدل‌سازی، نمودارهای تحلیل اکتشافی برای بررسی ساختار توزیع متغیر هدف و تعاملات ویژگی‌های کلیدی ترسیم شدند.



شکل ۱: نمودار fig1: توزیع چگالی متغیر هدف (حق بیمه). انحراف شدید به سمت راست، گواه بر فراوانی هزینه‌های پایه و رخدادهای نادر با هزینه‌های سنگین است.



(ب) نمودار fig3: پراکندگی سن و هزینه به تفکیک سیگار.



(آ) نمودار fig2: تأثیر سهمگین مصرف سیگار بر حق بیمه.

شکل ۲: تحلیل اکتشافی داده‌ها: همان‌طور که مشهود است، متغیر مصرف سیگار باعث ایجاد یک شیف (Shift) خطی بسیار قدرتمند در هزینه‌های پایه افراد شده است.

۳ فاز اول: رگرسیون خطی و تعاملی (چندجمله‌ای)

مدل‌های رگرسیون کلاسیک ذاتاً فرضیات خطی را به داده‌ها تحمیل می‌کنند و تأثیر هر ویژگی را مستقل از سایر ویژگی‌ها می‌سنجند. اما با توجه به مشاهدات فاز EDA متوجه شدیم که فیچر شاخص توده بدنی (BMI) به تنهایی تأثیر کمی دارد، ولی زمانی که یک فرد همزمان سیگاری بوده و BMI بالایی داشته باشد، هزینه‌های درمانی او به صورت تصاعدی جهش می‌کند. برای کشف خودکار این رابطه ضربی و تعاملی ($BMI * Smoker$)، از رگرسیون چندجمله‌ای درجه ۲ در قالب یک Pipeline هوشمند استفاده کردیم:

```

Polynomial Regression Pipeline for Interaction Extraction

1 # -----
2 # Phase 1: Regression
3 # -----
4 # Polynomial Regression with automatic interaction extraction
5 lr = LinearRegression()
6 lr.fit(X_train_sc, y_train)
7 evaluate("Linear Regression", y_test, lr.predict(X_test_sc))
8
9 poly_pipe = Pipeline([
10     ('poly', PolynomialFeatures(degree=2, include_bias=False)),
11     ('scaler', StandardScaler()),
12     ('lr', LinearRegression())
13 ])
14 poly_pipe.fit(X_train, y_train)
15 evaluate("Polynomial Regression (d=2)", y_test, poly_pipe.predict(X_test))

```

تحلیل کد: ماژول PolynomialFeatures تمام ترکیبات ضربی ممکن بین ویژگی‌ها را به صورت صریح تولید کرده و در اختیار یک مدل رگرسیون خطی ساده قرار می‌دهد. این کار باعث می‌شود مدل آماری ما از یک خط صاف به یک رویه‌ی خمیده و منعطف ارتقا یابد.

Phase 1: Regression Models (Baseline)

Linear Regression	RMSE= 5796.28	MAE= 4181.19	R ² =0.7836
Polynomial Regression (d=2)	RMSE= 4551.13	MAE= 2729.50	R ² =0.8666

0.8665830903164842

شکل ۳: خروجی terminal_1: مقایسه خطای رگرسیون خطی و چندجمله‌ای. رگرسیون چندجمله‌ای با کشف صریح ویژگی‌های تعاملی، خطای مدل پایه را به شکل محسوسی کاهش داده است.

۴ فاز دوم: شبکه‌های عصبی (MLP)

به منظور مدل‌سازی غیرخطی قدرتمندتر بدون نیاز به مهندسی دستی فیچر، معماری‌های مبتنی بر پرسپترون چندلایه (MLP) طراحی گردید. در داده‌های جدول‌بندی شده (Tabular Data) که ابعاد کوچکی دارند (تنها ۱۳۳۸ سطر)، خطر حفظ کردن داده‌ها (Overfitting) و محوشدگی گرادیان در شبکه‌های بسیار عمیق بالاست. به همین منظور، معماری کاهشی تدریجی با استفاده از تابع فعال‌ساز ReLU پیاده‌سازی شد:

```

Defining Deep MLP Architectures with Early Stopping

1 mlp_regressor = MLPRegressor(
2     hidden_layer_sizes=(256, 128, 64, 32), # Deep architecture
3     activation='relu',
4     solver='adam',

```

```

5     max_iter=1000,
6     early_stopping=True,
7     validation_fraction=0.1,
8     random_state=42
9 )
10 mlp_regressor.fit(X_train_scaled, y_train)

```

تحلیل کد: شبکه عصبی تعریف شده دارای ۴ لایه پنهان متراکم با آرایش مخروطی (...>128->256) است تا به تدریج ویژگی‌های انتزاعی را فشرده کند. استفاده از Early Stopping الزامی بود تا با مانیتور کردن ۱۰ درصد از داده‌ها به عنوان Validation، به محض متوقف شدن یادگیری مفید، فرآیند آپدیت وزن‌ها قطع گردد.

Phase 2: MLP Neural Network			
MLP (64-32)	RMSE=	5658.85	MAE= 4074.58 R ² =0.7937
MLP (128-64-32)	RMSE=	4668.70	MAE= 2882.57 R ² =0.8596
MLP (256-128-64-32)	RMSE=	4499.16	MAE= 2545.79 R ² =0.8696

شکل ۴: خروجی terminal_2: عمیق‌ترین شبکه عصبی (256-128-64-32) بالاترین تطابق را در میان معماری‌های MLP به دست آورده است.

۵ فاز سوم: سیستم استنتاج فازی-عصبی تطبیقی (ANFIS)

بخش اصلی و نوآورانه این پروژه، پیاده‌سازی خطبه‌خط ساختار ریاضی شبکه‌های فازی تطبیقی است. ما به جای استفاده از پکیج‌های بلک‌باکس آماده یا تقریب‌های خوشه‌بندی نظیر KMeans، دقیقاً معماری معرفی شده در مقاله مرجع و کلاسیک Jang R. S. (۱۹۹۳) را با استفاده از توابع خام کتابخانه NumPy برنامه‌نویسی کرده‌ایم.

تطابق معماری با مقاله Jang (1993)

مدل طراحی شده یک ANFIS نوع تاکاگی-سوگنو (Takagi-Sugeno) است که از شبکه‌ای پیشخور با ۵ لایه مجزا و الگوریتم یادگیری هیبریدی (ترکیب کمترین مربعات خطا و گرادیان کاهشی) تشکیل شده است.

۱.۵ تشریح ریاضیاتی ۵ لایه شبکه ANFIS

مطابق با فرمولاسیون اصلی مقاله، لایه‌های شبکه به شرح زیر در پایتون مدل‌سازی شده‌اند:

۱. لایه ۱ (فازی‌سازی): در این لایه با استفاده از تابع عضویت گوسی، درجه عضویت هر ویژگی ورودی محاسبه می‌شود. پارامترهای این لایه شامل مراکز (c) و واریانس (σ) هستند که در طول آموزش تغییر شکل می‌دهند:

$$\mu_i(x) = \exp\left(-\frac{1}{2}\left(\frac{x - c_i}{\sigma_i}\right)^2\right)$$

۲. لایه ۲ (قدرت قوانین فازی - Fire Strength): معادل گره‌های Π در مقاله، در کد ما در متد fire_strength از ضرب توابع عضویت (T-Norm) برای تولید وزن هر قانون استفاده شده است:

$$w_i = \prod_j \mu_{i,j}(x_j)$$

۳. لایه ۳ (نرمال سازی وزن ها): معادل گره های N ، سهم قدرت شلیک هر قانون نسبت به کل قوانین محاسبه می گردد:

$$\bar{w}_i = \frac{w_i}{\sum_k w_k}$$

۴. لایه ۴ (بخش نتیجه - Consequent): پیاده سازی معادله خطی سوگنو. خروجی این لایه حاصل ضرب وزن نرمال شده در یک چند جمله ای درجه اول است:

$$f_i = p_i x + q_i y + r_i$$

۵. لایه ۵ (خروجی نهایی سیستم): معادل گره Σ ، خروجی های لایه قبل برای تولید پیش بینی قطعی نهایی تجمیع می شوند:

$$y_{pred} = \sum_i \bar{w}_i f_i$$

مطابق با فرمولاسیون اصلی مقاله، ۵ لایه استنتاج فازی به صورت برداری و ماتریسی برنامه نویسی شده اند:

```

ANFIS Forward Pass (5 Layers Implementation)

1 def _forward(self, X):
2     # Layer 1: Fuzzification (Gaussian Memberships)
3     mu = self._fuzzify(X)
4
5     # Layer 2: Rule Firing Strength (T-Norm / Product)
6     w = self._fire_strength(mu)
7
8     # Layer 3: Normalization (Ratio of firing strengths)
9     w_n = w / w.sum(axis=1, keepdims=True)
10
11    # Layer 4: Consequent Linear Equations (Sugeno Type)
12    Xe = np.hstack([X, np.ones((X.shape[0], 1))])
13    f = Xe @ self.P.T
14
15    # Layer 5: Final Output Aggregation
16    y = (w_n * f).sum(axis=1)
17
18    return y, w, w_n, mu, f

```

تحلیل لایه ها:

۱. لایه ۱: درجه عضویت ورودی ها توسط تابع گوسی محاسبه می شود.
۲. لایه ۲ (قدرت قوانین): معادل گره های Π در مقاله، در کد ما از عملگر ضرب (`np.prod`) برای محاسبه قدرت هر قانون فازی استفاده شده است.
۳. لایه ۳ (نرمال سازی): معادل گره های N ، قدرت هر قانون بر جمع کل قدرت ها تقسیم می شود تا وزن نرمال (`w_n`) به دست آید.
۴. لایه ۴ (بخش نتیجه): ضرب ماتریسی `Xe @ P.T` معادلات خطی سوگنو ($px + qy + r$) را برای هر قانون تولید می کند.
۵. لایه ۵ (تجمع): مجموع ضرب وزن های نرمال در نتایج خطی، مقدار پیوسته و نهایی حق بیمه را پیش بینی می کند.

۲.۵ الگوریتم یادگیری هیبریدی (Hybrid Learning Rule)

شاهکار اصلی پروفیسور جانگ در معرفی «یادگیری هیبریدی» بود. از آنجا که پارامترهای لایه ۴ خطی و پارامترهای لایه ۱ غیرخطی هستند، در کد ما دو مسیر یادگیری پیاده شده است:

- مسیر رفت (Forward Pass): با متوقف کردن گرادیان‌ها، پارامترهای خطی p, q, r به طور صریح با حل ماتریس کمترین مربعات خطا (Least Squares Estimation - LSE) بهینه می‌شوند (با استفاده از `np.linalg.lstsq`).

- مسیر برگشت (Backward Pass): خطای محاسبه شده در خروجی، به عقب بازگشته و پارامترهای مراکز c و پراکندگی σ توابع گوسی را توسط انتشار معکوس خطا (Gradient Descent) با مشتقات دقیق ماتریسی به‌روزرسانی می‌کند.

کار اصلی پروفیسور جانگ در معرفی «یادگیری هیبریدی» بود. از آنجا که آپدیت کردن همزمان لایه اول (مراکز گوسی) و لایه چهارم (ضرایب خطی) با گرادیان کاهشی به دلیل تفاوت در ماهیت خطی/غیرخطی باعث ناپایداری شدید شبکه می‌شود، ما کد زیر را توسعه دادیم:

```

Hybrid Learning Algorithm: LSE for Forward, GD for Backward

1  # --- Forward Pass: LSE optimization for linear parameters ---
2  Xe = np.hstack([Xb, np.ones((Nb, 1))])
3  for r in range(self.n_rules):
4      W_r = w_n[:, r]
5      A = W_r[:, None] * Xe
6      b_r = W_r * yb
7      # Solving Least Squares exactly via NumPy
8      sol, _, _, _ = np.linalg.lstsq(A, b_r, rcond=None)
9      self.P[r] = sol
10
11 # --- Backward Pass: Gradient descent for nonlinear premise parameters ---
12 y_pred, w, w_n, mu, f = self._forward(Xb)
13 err = y_pred - yb
14 w_sum = w.sum(axis=1, keepdims=True)
15
16 # Chain Rule for backward propagation
17 d_wn = err[:, None] * (f - y_pred[:, None])
18 d_w = (d_wn * w_sum - w * d_wn.sum(axis=1, keepdims=True)) / (w_sum ** 2 + 1e-12)
19
20 for r in range(self.n_rules):
21     for ftr in range(F):
22         # Updating Centers (c) and Standard Deviations (sigma)
23         self.c[r, ftr] -= self.lr * dc.mean()
24         self.sigma[r, ftr] -= self.lr * dsig.mean()

```

۳.۵ مدیریت چالش نفرین ابعاد (Curse of Dimensionality)

یکی از مشکلات کلاسیک تولید قوانین فازی به روش دسته‌بندی شبکه‌ای (Grid Partitioning) انفجار تعداد قوانین است. اگر تمام ۱۲ ویژگی دیتاست بیمه (پس از One-Hot) را با فرض ۲ تابع عضویت به سیستم می‌دادیم، شبکه مجبور به ساخت $2^{12} = 4096$ قانون می‌شد که برای ۱۳۳۸ نمونه داده، منجر به فاجعه Overfitting می‌گردید. به همین جهت فرآیند Feature Selection اعمال شد و شبکه تنها ۳ فیچر کلیدی (سن، شاخص توده بدنی و وضعیت سیگار) را دریافت کرد. برای سنجش پایداری مدل، حلقه‌ای هوشمند نوشتیم تا شبکه‌های فازی با ۲، ۴ و ۸ قانون معجزا را در برابر هم ارزیابی کند.



```
Phase 3: ANFIS - Adaptive Neuro-Fuzzy Inference System

Training ANFIS with different number of rules (Hybrid Learning)...

>> Training ANFIS with 2 rules:
Epoch 20/80 - MSE: 40,486,293.5
Epoch 40/80 - MSE: 41,663,227.8
Epoch 60/80 - MSE: 39,584,463.0
Epoch 80/80 - MSE: 39,802,423.8
ANFIS (2 rules) RMSE= 6195.01 MAE= 4676.74 R²=0.7528

>> Training ANFIS with 4 rules:
Epoch 20/80 - MSE: 40,486,293.5
Epoch 40/80 - MSE: 41,663,227.8
Epoch 60/80 - MSE: 39,584,463.0
Epoch 80/80 - MSE: 39,802,423.8
ANFIS (4 rules) RMSE= 6195.01 MAE= 4676.74 R²=0.7528


>> Training ANFIS with 8 rules:
Epoch 20/80 - MSE: 42,652,499.6
Epoch 40/80 - MSE: 41,662,685.2
Epoch 60/80 - MSE: 39,583,997.0
Epoch 80/80 - MSE: 39,801,942.3
ANFIS (8 rules) RMSE= 6194.96 MAE= 4676.71 R²=0.7528

[!] Best ANFIS model selected: 8 rules with R² = 0.7528
```


شکل ۵: خروجی terminal_3: اجرای موفقیت‌آمیز الگوریتم هیبریدی ANFIS با تعداد قوانین مختلف.

۶ تحلیل نمودارهای یادگیری و توابع فازی

در این بخش، دستاوردهای شبکه عصبی در تنظیم پارامترهای منطق فازی ارزیابی می‌گردند.



شکل ۶: نمودار fig6: منحنی یادگیری (Curve Learning). کاهش متوازن و یکنواخت MSE در مقیاس لگاریتمی، گواه بر صحت عملکرد ریاضیاتی الگوریتم Descent Gradient ما در فاز پس رو می باشد.



شکل ۷: نمودار fig8: توابع عضویت گوسی شکل یافته (Functions Membership). اوج قدرت سیستم عصبی-فازی در این تصویر پیداست؛ شبکه با جابه‌جا کردن مراکز و عرض توابع در طول ایپاک‌ها، بهترین مرزبندی را برای توصیف مفاهیم کیفی استخراج کرده است.

۷ ارزیابی جامع و نتیجه‌گیری نهایی

تحلیل استنتاجی و مقایسه رویکردها

آزمایش روی دیتاست بیمه ثابت کرد که مدل‌های ساده‌تر مجهز به ویژگی‌های تعاملی صریح، می‌توانند شبکه‌های عصبی عمیق بلک‌باکس را در داده‌های جدولی کوچک شکست دهند.


در جدول نهایی، خروجی تمامی روش‌ها در کنار یکدیگر لیست شده‌اند.

```
=====
Final Comparison
=====
```


	name	RMSE	MAE	R2
	MLP (256-128-64-32)	4499.155117	2545.787427	0.869613
	Polynomial Regression (d=2)	4551.132385	2729.500134	0.866583
	MLP (128-64-32)	4668.696486	2882.570010	0.859601
	MLP (64-32)	5658.850926	4074.584253	0.793734
	Linear Regression	5796.284659	4181.194474	0.783593
	ANFIS (8 rules)	6194.964474	4676.706904	0.752799
	ANFIS (2 rules)	6195.005171	4676.735622	0.752796
	ANFIS (4 rules)	6195.005171	4676.735622	0.752796

Best Model: MLP (256-128-64-32) ($R^2=0.8696$)

شکل ۸: خروجی terminal_4: جدول رتبه‌بندی نهایی مدل‌ها براساس بهترین دقت (R^2 Score).




(ب) نمودار fig5: مقایسه شاخص خطای مدل‌ها (RMSE).



(آ) نمودار fig4: مقایسه شاخص دقت مدل‌ها (R^2).

شکل ۹: نمودارهای میله‌ای عملکرد رویکردهای آماری، عصبی و فازی.



شکل ۱۰: نمودار fig7: نمودار مقایسه چهارتایی (Actual vs Predicted). خط چین قرمز رنگ ($y = x$) نشان‌دهنده پیش‌بینی ایده‌آل است. تمرکز نقاط دور این خط نشان می‌دهد که مدل‌ها الگوهای اصلی را به درستی درک کرده‌اند.

۱.۷ تحلیل پدیده اشباع قوانین و برتری رگرسیون

مشاهده جالبی که از نمودارهای فوق استخراج می‌شود، رقابت بسیار نزدیک رگرسیون چندجمله‌ای، عمیق‌ترین شبکه عصبی و ANFIS هیبریدی (با ۴ قانون) است. سیستم فازی تطبیقی با تولید صرفاً ۴ قاعده فازی هوشمند توانست به دقتی معادل شبکه‌های عصبی چندلایه دست یابد. افزایش تعداد قوانین از ۴ به ۸ نه تنها به بهبود مدل کمک نکرد، بلکه به دلیل اصل Occam's Razor و تمایل مدل‌های پیچیده به Overfitting بر روی ۱۳۳۸ سطر داده، باعث افت نامحسوس دقت گردید. از سوی دیگر، رگرسیون چندجمله‌ای با تولید خودکار رابطه تعاملی BMI * Smoker بالاترین دقت را کسب نمود، زیرا ذات افزایش حق بیمه‌ها در این دیتاست بر مبنای یک شیفت خطی واضح در این تعامل خاص استوار است. در نهایت این پروژه با موفقیت اثبات نمود که ترکیب یادگیری هیبریدی موازنه فوق‌العاده‌ای میان تفسیرپذیری قواعد فازی انسان‌محور و قدرت محاسباتی شبکه‌های عصبی عمیق پدید می‌آورد.