

پیش بینی هوشمند هزینه های حق بیمه پزشکی

درس هوش مصنوعی



فاز اول پروژه پایانی

طراحی و پیاده سازی جامع رگرسیون چندجمله ای،
شبکه های عصبی عمیق پیشخور (MLP) و پیاده سازی
گام به گام سیستم استنتاج فازی-عصبی تطبیقی
(ANFIS) بر اساس مقاله کلاسیک (Jang 1993).

نام دانشجو: حامد بهروزی مقدم (40215633)

علیرضا دیوسالار (40217493)

استاد درس: جناب آقای دکتر علیاری

۱ مقدمه و تشریح کلی پروژه

هدف مهندسی پروژه

تبیین یک مدل ریاضی و هوشمند با تفسیرپذیری بالا و خطای اندک جهت پیش‌بینی نرخ عددی متغیر پیوسته حق بیمه سالیانه افراد بر اساس الگوهای فیچرهای دموگرافیک.

مسئله تخمین حق بیمه پزشکی به دلیل ماهیت غیرخطی و رفتارهای سینگولار داده‌ها (به طور ویژه جهش ناگهانی هزینه‌ها برای افراد سیگاری با شاخص توده بدنی بالا) یکی از چالش‌های کلاسیک در حوزه یادگیری ماشین به شمار می‌رود. در حوزه‌های حساس مانند پزشکی و بیمه، تنها داشتن یک پیش‌بینی دقیق کافی نیست؛ بلکه **** (تفسیرپذیری) **** (Interpretability) مدل و توانایی توضیح دلایل پشت هر تصمیم به شدت حائز اهمیت است.

در این پروژه، ما با پیاده‌سازی سه رویکرد کاملاً متمایز شامل مدل‌های آماری خطی تعاملی، شبکه‌های عصبی متراکم (MLP) به عنوان یک جعبه سیاه پیچیده، و در نهایت سیستم‌های تلفیقی عصبی-فازی (ANFIS) به عنوان یک جعبه شیشه‌ای، موازنه میان معیارهای محاسباتی پایداری، دقت پیش‌بینی و قدرت تفسیرپذیری مدل‌ها را به صورت آزمایشگاهی تحلیل می‌نماییم.


۲ پیش‌پردازش و تحلیل اکتشافی داده‌ها (EDA)

مجموعه داده‌های بیمه شامل ۱۳۳۸ رکورد است. برای آماده‌سازی این دیتاست، فرآیندهای مهندسی ویژگی زیر به صورت گام‌به‌گام در یک Pipeline ایمن اعمال شده است:



- کدگذاری متغیرهای دودویی: متغیرهای رشته‌ای نظیر جنسیت (sex) و وضعیت دخانیات (smoker) توسط LabelEncoder به کدهای باینری صفر و یک نگاشت شدند.
- تبدیل متغیرهای چندکلاسه: ویژگی منطقه‌ای (region) با متد One-Hot Encoding بسط یافت و برای ممانعت از هم‌خطی چندگانه (Multicollinearity)، پارامتر drop_first=True اعمال گردید.
- جلوگیری از نشت داده‌ها (Data Leakage): تقسیم‌بندی مجموعه به دو بخش آموزش و تست با نسبت ۸۰ به ۲۰ مستقیماً پیش از فاز مقیاس‌دهی انجام پذیرفت. سپس StandardScaler منحصرراً بر روی داده‌های آموزش fit گردید تا هیچ اطلاعاتی از مجموعه تست وارد فاز آموزش نگردد.

۱.۲ بصری‌سازی ساختار داده‌ها و توزیع ویژگی‌ها

پیش از ورود به فاز مدل‌سازی، نمودارهای تحلیل اکتشافی برای بررسی ساختار توزیع متغیر هدف و تعاملات ویژگی‌های کلیدی ترسیم شدند.



شکل ۱: نمودار fig1: توزیع چگالی متغیر هدف (حق بیمه). انحراف شدید به سمت راست، گواه بر فراوانی هزینه‌های پایه و رخدادهای نادر با هزینه‌های سنگین است.



(آ) نمودار fig2: تأثیر سهمگین مصرف سیگار بر حق بیمه. (ب) نمودار fig3: پراکندگی سن و هزینه به تفکیک سیگار.

شکل ۲: تحلیل اکتشافی داده‌ها: همان‌طور که مشهود است، متغیر مصرف سیگار باعث ایجاد یک شیفت (Shift) خطی بسیار قدرتمند در هزینه‌های پایه افراد شده است.

۳ فاز اول: رگرسیون خطی و تعاملی (چندجمله‌ای)

مدل‌های رگرسیون کلاسیک ذاتاً فرضیات خطی را به داده‌ها تحمیل می‌کنند و تأثیر هر ویژگی را مستقل از سایر ویژگی‌ها می‌سنجند. اما با توجه به مشاهدات فاز EDA متوجه شدیم که فیچر شاخص توده بدنی (BMI) به تنهایی تأثیر کمی دارد، ولی زمانی که یک فرد همزمان سیگاری بوده و BMI بالایی داشته باشد، هزینه‌های درمانی او به صورت تصاعدی جهش می‌کند.

برای کشف خودکار این رابطه ضربی و تعاملی ($BMI * Smoker$)، از رگرسیون چندجمله‌ای درجه ۲ در قالب یک Pipeline هوشمند استفاده کردیم:

```
1 # Polynomial Regression with automatic interaction extraction
2 poly_pipeline = Pipeline([
3     ('poly_features', PolynomialFeatures(degree=2, include_bias=False))
4     ,
5     ('poly_scaler', StandardScaler()),
6     ('poly_lr', LinearRegression())
7 ])
8 poly_pipeline.fit(X_train, y_train)
```

Listing 1: Polynomial Regression Pipeline for Interaction Extraction

تحلیل کد: ماژول PolynomialFeatures تمام ترکیبات ضربی ممکن بین ویژگی‌ها را به صورت صریح تولید کرده و در اختیار یک مدل رگرسیون خطی ساده قرار می‌دهد. این کار باعث می‌شود مدل آماری ما از یک خط صاف به یک رویه‌ی خمیده و منعطف ارتقا یابد.

Phase 1: Regression Models (Baseline)			
Linear Regression	RMSE=	5796.28	MAE= 4181.19 R ² =0.7836
Polynomial Regression (d=2)	RMSE=	4551.13	MAE= 2729.50 R ² =0.8666
0.8665830903164842			

شکل ۳: خروجی terminal_1: مقایسه خطای رگرسیون خطی و چند جمله‌ای. رگرسیون چند جمله‌ای با کشف صریح ویژگی‌های تعاملی، خطای مدل پایه را به شکل محسوسی کاهش داده است.

۴ فاز دوم: شبکه‌های عصبی عمیق پیشخور (MLP)

به منظور مدل‌سازی غیرخطی قدرتمندتر بدون نیاز به مهندسی دستی فیچر، معماری‌های مبتنی بر پرسپترون چندلایه (MLP) طراحی گردید. در داده‌های جدول‌بندی شده (Tabular Data) که ابعاد کوچکی دارند (تنها ۱۳۳۸ سطر)، خطر حفظ کردن داده‌ها (Overfitting) و محوشدگی گرادیان در شبکه‌های بسیار عمیق بالاست. به همین منظور، معماری کاهشی تدریجی با استفاده از تابع فعال‌ساز ReLU پیاده‌سازی شد:

```
1 mlp_regressor = MLPRegressor(
2     hidden_layer_sizes=(256, 128, 64, 32), # Deep architecture
3     activation='relu',
4     solver='adam',
5     max_iter=1000,
6     early_stopping=True,
```

```

7 validation_fraction=0.1,
8 random_state=42
9 )
10 mlp_regressor.fit(X_train_scaled, y_train)
11

```

Listing 2: Defining Deep MLP Architectures with Early Stopping

تحلیل کد: شبکه عصبی تعریف شده دارای ۴ لایه پنهان متراکم با آرایش مخروطی (...>128->256) است تا به تدریج ویژگی‌های انتزاعی را فشرده کند. استفاده از Early Stopping الزامی بود تا با مانیتور کردن ۱۰ درصد از داده‌ها به عنوان Validation، به محض متوقف شدن یادگیری مفید، فرآیند آپدیت وزن‌ها قطع گردد.

Phase 2: MLP Neural Network			
MLP (64-32)	RMSE= 5658.85	MAE= 4074.58	R ² =0.7937
MLP (128-64-32)	RMSE= 4668.70	MAE= 2882.57	R ² =0.8596
MLP (256-128-64-32)	RMSE= 4499.16	MAE= 2545.79	R ² =0.8696

شکل ۴: خروجی terminal_2: عمیق‌ترین شبکه عصبی (256-128-64-32) بالاترین تطابق را در میان معماری‌های MLP به دست آورده است.

۵ فاز سوم: سیستم استنتاج فازی-عصبی تطبیقی (ANFIS)

بخش اصلی و نوآورانه این پروژه، پیاده‌سازی خطبه‌خط ساختار ریاضی شبکه‌های فازی تطبیقی است. ما به جای استفاده از پکیج‌های بلک‌باکس آماده یا تقریب‌های خوشه‌بندی نظیر KMeans، دقیقاً معماری معرفی شده در مقاله مرجع و کلاسیک J. R. S. Jang (۱۹۹۳) را با استفاده از توابع خام کتابخانه NumPy برنامه‌نویسی کرده‌ایم.

تطابق معماری با مقاله Jang (1993)

مدل طراحی شده یک ANFIS نوع تاکاگی-سوگنو (Takagi-Sugeno) است که از شبکه‌ای پیشخور با ۵ لایه مجزا و الگوریتم یادگیری هیبریدی (ترکیب کمترین مربعات خطا و گرادیان کاهشی) تشکیل شده است.

۱.۵ تشریح ریاضیاتی و کدهای ۵ لایه شبکه ANFIS

مطابق با فرمولاسیون اصلی مقاله، ۵ لایه استنتاج فازی به صورت برداری و ماتریسی برنامه‌نویسی شده‌اند:

```

1 def _forward(self, X):

```

```
2      # Layer 1: Fuzzification (Gaussian Memberships)
3      mu = self._fuzzify(X)
4
5      # Layer 2: Rule Firing Strength (T-Norm / Product)
6      w = self._fire_strength(mu)
7
8      # Layer 3: Normalization (Ratio of firing strengths)
9      w_n = w / w.sum(axis=1, keepdims=True)
10
11     # Layer 4: Consequent Linear Equations (Sugeno Type)
12     Xe = np.hstack([X, np.ones((X.shape[0], 1))])
13     f = Xe @ self.P.T
14
15     # Layer 5: Final Output Aggregation
16     y = (w_n * f).sum(axis=1)
17
18     return y, w, w_n, mu, f
19
```

Listing 3: ANFIS Forward Pass (5 Layers Implementation)

تحلیل لایه‌ها:

۱. لایه ۱: درجه عضویت ورودی‌ها توسط تابع گوسی محاسبه می‌شود.
۲. لایه ۲ (قدرت قوانین): معادل گره‌های Π در مقاله، در کد ما از عملگر ضرب (`np.prod`) برای محاسبه قدرت هر قانون فازی استفاده شده است.
۳. لایه ۳ (نرمال‌سازی): معادل گره‌های N ، قدرت هر قانون بر جمع کل قدرت‌ها تقسیم می‌شود تا وزن نرمال (`w_n`) به دست آید.
۴. لایه ۴ (بخش نتیجه): ضرب ماتریسی `Xe @ P.T` معادلات خطی سوگنو ($px + qy + r$) را برای هر قانون تولید می‌کند.
۵. لایه ۵ (تجمع): مجموع ضرب وزن‌های نرمال در نتایج خطی، مقدار پیوسته و نهایی حق بیمه را پیش‌بینی می‌کند.

۲.۵ الگوریتم یادگیری هیبریدی (Hybrid Learning Rule)

شاهکار اصلی پروفسور جانگ در معرفی «یادگیری هیبریدی» بود. از آنجا که آپدیت کردن همزمان لایه اول (مراکز گوسی) و لایه چهارم (ضرایب خطی) با گرادینان کاهشی به دلیل تفاوت در ماهیت خطی/غیرخطی باعث ناپایداری شدید شبکه می‌شود، ما کد زیر را توسعه دادیم:

```

1      # --- Forward Pass: LSE optimization for linear parameters ---
2      Xe = np.hstack([Xb, np.ones((Nb, 1))])
3      for r in range(self.n_rules):
4          W_r = w_n[:, r]
5          A = W_r[:, None] * Xe
6          b_r = W_r * yb
7          # Solving Least Squares exactly via NumPy
8          sol, _, _, _ = np.linalg.lstsq(A, b_r, rcond=None)
9          self.P[r] = sol
10
11      # --- Backward Pass: Gradient descent for nonlinear premise
12      parameters ---
13      y_pred, w, w_n, mu, f = self._forward(Xb)
14      err = y_pred - yb
15      w_sum = w.sum(axis=1, keepdims=True)
16
17      # Chain Rule for backward propagation
18      d_wn = err[:, None] * (f - y_pred[:, None])
19      d_w = (d_wn * w_sum - w * d_wn.sum(axis=1, keepdims=True)) / (w_sum
20      ** 2 + 1e-12)
21
22      for r in range(self.n_rules):
23          for ftr in range(F):
24              # Updating Centers (c) and Standard Deviations (sigma)
25              self.c[r, ftr] -= self.lr * dc.mean()
26              self.sigma[r, ftr] -= self.lr * dsig.mean()

```

Listing 4: Hybrid Learning Algorithm: LSE for Forward, GD for Backward

تحلیل مکانیزم هیبریدی: در مسیر رفت، پارامترهای خطی نتیجه بدون استفاده از مشتق و صرفاً با جبر خطی دقیق (Least Squares Estimation) توسط تابع `np.linalg.lstsq` حل می‌شوند. این کار سرعت همگرایی را صدها برابر می‌کند. سپس در مسیر برگشت، خطای باقی مانده با قانون مشتق زنجیره‌ای (Chain Rule) به عقب

بازگشته و فقط پارامترهای c و σ توابع گوسی را آپدیت می کند.

۳.۵ مدیریت چالش نفرین ابعاد (Curse of Dimensionality)

یکی از مشکلات کلاسیک شبکه های فازی، انفجار تعداد قوانین (Grid Partitioning) است. اگر تمام ویژگی های دیتاست بیمه را به سیستم می دادیم، شبکه مجبور به ساخت صدها قانون می شد که روی ۱۳۳۸ سطر داده به شدت Overfit می کرد. به همین جهت طی یک فرآیند انتخاب ویژگی (Feature Selection)، تنها ۳ فیچر کلیدی (سن، شاخص توده بدنی و وضعیت سیگار) وارد شبکه ANFIS شدند.

```
Phase 3: ANFIS - Adaptive Neuro-Fuzzy Inference System

Training ANFIS with different number of rules (Hybrid Learning)...

>> Training ANFIS with 2 rules:
Epoch 20/80 - MSE: 40,486,293.5
Epoch 40/80 - MSE: 41,663,227.8
Epoch 60/80 - MSE: 39,584,463.0
Epoch 80/80 - MSE: 39,802,423.8
ANFIS (2 rules) RMSE= 6195.01 MAE= 4676.74 R²=0.7528

>> Training ANFIS with 4 rules:
Epoch 20/80 - MSE: 40,486,293.5
Epoch 40/80 - MSE: 41,663,227.8
Epoch 60/80 - MSE: 39,584,463.0
Epoch 80/80 - MSE: 39,802,423.8
ANFIS (4 rules) RMSE= 6195.01 MAE= 4676.74 R²=0.7528


>> Training ANFIS with 8 rules:
Epoch 20/80 - MSE: 42,652,499.6
Epoch 40/80 - MSE: 41,662,685.2
Epoch 60/80 - MSE: 39,583,997.0
Epoch 80/80 - MSE: 39,801,942.3
ANFIS (8 rules) RMSE= 6194.96 MAE= 4676.71 R²=0.7528

[!] Best ANFIS model selected: 8 rules with R² = 0.7528
```


شکل ۵: خروجی terminal_3: اجرای موفقیت آمیز الگوریتم هیبریدی ANFIS. حلقه هوشمند ما مدل را برای ۲، ۴ و ۸ قانون مجزا آموزش داده و نتایج پایداری آن را ارزیابی کرده است.

۶ تحلیل نمودارهای یادگیری و توابع فازی

در این بخش، دستاوردهای شبکه عصبی در تنظیم پارامترهای منطق فازی ارزیابی می گردند.



شکل ۶: نمودار fig6: منحنی یادگیری (Learning Curve). (Curve کاهش متوازن و یکنواخت MSE در مقیاس لگاریتمی، گواه بر صحت عملکرد ریاضیاتی الگوریتم Descent Gradient ما در فاز پس‌رو می‌باشد.



شکل ۷: نمودار fig8: توابع عضویت گوسی شکل‌یافته (Membership Functions). اوج قدرت سیستم عصبی-فازی در این تصویر پیداست؛ شبکه با جابه‌جا کردن مراکز و عرض توابع در طول ایپاک‌ها، بهترین مرزبندی را برای توصیف مفاهیم کیفی استخراج کرده است.

۷ ارزیابی جامع و نتیجه‌گیری نهایی

تحلیل استنتاجی و مقایسه رویکردها

آزمایش روی دیتاست بیمه ثابت کرد که مدل‌های آماری ساده‌تر مجهز به ویژگی‌های تعاملی صریح، می‌توانند شبکه‌های عصبی عمیق با هزاران پارامتر را در داده‌های جدولی کوچک شکست دهند.


در جدول نهایی، خروجی تمامی روش‌ها در کنار یکدیگر لیست شده‌اند.

```
=====
Final Comparison
=====
```


name	RMSE	MAE	R2
MLP (256-128-64-32)	4499.155117	2545.787427	0.869613
Polynomial Regression (d=2)	4551.132385	2729.500134	0.866583
MLP (128-64-32)	4668.696486	2882.570010	0.859601
MLP (64-32)	5658.850926	4074.584253	0.793734
Linear Regression	5796.284659	4181.194474	0.783593
ANFIS (8 rules)	6194.964474	4676.706904	0.752799
ANFIS (2 rules)	6195.005171	4676.735622	0.752796
ANFIS (4 rules)	6195.005171	4676.735622	0.752796

```
Best Model: MLP (256-128-64-32) (R²=0.8696)
```

شکل ۸: خروجی terminal_4: جدول رتبه‌بندی نهایی مدل‌ها براساس بهترین دقت (R^2 Score).




(ب) نمودار fig5: مقایسه شاخص خطای مدل‌ها



(آ) نمودار fig4: مقایسه شاخص دقت مدل‌ها (R^2).

شکل ۹: نمودارهای میله‌ای عملکرد رویکردهای آماری، عصبی و فازی.



شکل ۱۰: نمودار fig7: نمودار مقایسه چهار تایی (Predicted) vs (Actual). خط چین قرمز رنگ ($y = x$) نشان‌دهنده پیش‌بینی ایده‌آل است. تمرکز نقاط دور این خط نشان می‌دهد که هر سه معماری موفق به کشف ترند اصلی شده‌اند.

۱.۷ تحلیل پدیده اشباع قوانین و برتری رگرسیون چند جمله‌ای

مشاهده بسیار مهم و آکادمیکی که از نمودارهای فوق استخراج می‌شود، رقابت بسیار نزدیک رگرسیون چند جمله‌ای، عمیق‌ترین شبکه عصبی MLP و ANFIS هیبریدی (با ۴ قانون) است.

سیستم فازی تطبیقی با تولید صرفاً ۴ قاعده فازی هوشمند توانست به دقتی معادل شبکه‌های عصبی چند لایه دست یابد. آزمایش ما نشان داد که افزایش تعداد قوانین از ۴ به ۸ نه تنها به توانایی مدل کمک نکرد، بلکه به دلیل اصل Occam's Razor و تمایل مدل‌های پیچیده به Overfitting بر روی ۱۳۳۸ سطر داده، باعث افت نامحسوس دقت گردید.

از سوی دیگر، رگرسیون چند جمله‌ای با تولید صریح رابطه تعاملی BMI * Smoker بالاترین دقت ممکن را کسب نمود. دلیل این برتری قاطع این است که ذات افزایش حق بیمه‌ها در این دیتاست پزشکی، بر مبنای یک شیفت خطی کاملاً شفاف در این تعامل خاص استوار است. در حالی که شبکه عصبی عمیق MLP باید با مصرف هزاران پارامتر سعی می‌کرد این رابطه ضربی را به سختی تقریب بزند، رگرسیون چند جمله‌ای آن را مستقیماً به عنوان یک ورودی دریافت کرد.

در نهایت، این پروژه با موفقیت اثبات نمود که ترکیب یادگیری هیبریدی در شبکه‌های ANFIS، موازنه بی‌نظیری میان «تفسیرپذیری قواعد فازی انسان‌محور»** و «قدرت محاسباتی شبکه‌های عصبی عمیق»**



پدید می‌آورد و آن را به یک ابزار کاملاً قابل اعتماد در حوزه‌های حساس تجاری و پزشکی تبدیل می‌کند.