

به نام خدا

پیش بینی هزینه های بیمه پزشکی با مدل های یادگیری هیبرید

پروژه نهایی درس هوش مصنوعی مقدماتی

تحلیل آماری رگرسیون چندجمله ای، شبکه های عصبی MLP و پیاده سازی سیستم ANFIS

دانشجویان: علی رضا دیوسالار (۴۰۲۱۷۴۹۳) و حامد بهروزی مقدم (۴۰۲۱۵۶۳۳)

استاد راهنما: آقای دکتر علیاری

دانشگاه صنعتی خواجه نصیرالدین طوسی

مقدمه و هدف مهندسی پروژه


چالش‌های تخمین حق بیمه در پزشکی

● ماهیت غیرخطی و رفتارهای تکین (Singular):

توزیع آماری هزینه‌های درمانی نشان‌دهنده ناهمگونی شدیدی است؛ ویژگی‌هایی نظیر سن و BMI به صورت تکی رفتار ملایمی دارند، اما تلاقی آن‌ها با وضعیت دخانیات باعث جهش سهمگین در متغیر هدف می‌شود [3].

● اهمیت بالا و حیاتی تفسیرپذیری (Interpretability):

در سامانه‌های تصمیم‌یار بالینی و بیمه، صرفاً داشتن دقت بالا کافی نیست. مدل هوشمند باید قابلیت تبیین و ارائه دلایل ریاضی شفاف پشت هر تصمیم و پیش‌بینی را دارا باشد [3, 4].



۱. مدل آماری رگرسیون (جعبه سفید)

تفسیرپذیری کامل پارامترهای مدل اما محدودیت مطلق در کشف تعاملات پیچیده غیرخطی بدون استخراج دستی ویژگی‌های تعاملی [4].

۲. شبکه عصبی MLP (جعبه سیاه)

مدل‌سازی فوق‌العاده قوی و بدون نیاز به استخراج دستی الگوهای چندبعدی، با این تفاوت که وزن لایه‌ها برای انسان قابل تفسیر نیست [4].

۳. معماری تلفیقی ANFIS (جعبه شیشه‌ای)

سیستم استنتاج فازی-عصبی تطبیقی؛ ترکیب هوشمندانه استدلال فازی انسان‌محور (تفسیرپذیری بالا) و توان یادگیری بهینه‌ساز شبکه عصبی چندلایه [4].

پیش‌پردازش داده‌ها و تحلیل اکتشافی (EDA)

۱. رمزگذاری دودویی

Label Encoding

متغیرهای اسمی باینری نظیر جنسیت (sex) و مصرف دخانیات (smoker) توسط انکودر به مقادیر عددی ۰ و ۱ نگاشت شدند تا ورود آن‌ها به مدل‌های عددی میسر شود [5].

۲. تبدیل چندکلاسه‌ها

One-Hot Encoding

ویژگی منطقه جغرافیایی (region) با الگوریتم One-Hot باز شد و برای جلوگیری از پدیده هم‌خطی (Multicollinearity)، پارامتر drop_first=True اعمال گردید [5].

۳. جلوگیری از نشت داده

Data Leakage Guard


تقسیم داده‌ها به نسبت ۸۰ به ۲۰ برای آموزش و تست صورت گرفت. مقیاس‌دهی با StandardScaler منحصراً به مجموعه آموزش انجام و سپس فیت آن روی داده تست پیاده شد [5, 6].

۴. تحلیل توزیع‌ها

EDA Insights

توزیع متغیر هدف (حق بیمه) چولگی شدید به راست دارد (هزینه‌های پایه رایج و رخدادهای نادر گران). اثر مصرف سیگار به وضوح مرز داده‌ها را شیفت داده و متمایز می‌کند [6].

Medical Cost Distribution



فاز اول: رگرسیون چندجمله‌ای و اثر تعاملی BMI * Smoker

کشف خودکار اثرات متقابل متغیرها

● ماهیت پنهان اثر تعاملی (Interaction Effects):

یافته‌های تحلیل اکتشافی نشان داد شاخص توده بدنی (BMI) به خودی خود همبستگی خطی ضعیفی با هزینه‌ها دارد، اما همزمانی شاخص توده بدنی بالا و وضعیت سیگاری بودن فرد، هزینه‌های درمانی را به صورت انفجاری و غیرخطی افزایش می‌دهد [7].

● پیاده‌سازی هوشمند Pipeline چندجمله‌ای:

با طراحی Pipeline شامل ماژول PolynomialFeatures درجه ۲، تمامی ترکیبات ضربی ممکن بین ویژگی‌ها به طور صریح تولید شدند [7, 8]. این کار خط مستوی رگرسیون ساده را به یک رویه خمیده و بسیار منعطف تبدیل کرد [9].

رگرسیون خطی کلاسیک (Linear Regression)

● ضریب تبیین: $R^2 = 0.7836$

● میانگین مجذور خطای ریشه: $RMSE = 5796.28$

● میانگین قدر مطلق خطا: $MAE = 4181.19$

تحلیل فرضیات کاملاً خطی و عدم توانایی در درک همبستگی ضربی متغیرها.

رگرسیون چندجمله‌ای درجه ۲ (Polynomial Regression d=2)

● ضریب تبیین: $R^2 = 0.8666$ (ارتقای چشمگیر دقت)

● میانگین مجذور خطای ریشه: $RMSE = 4551.13$

● میانگین قدر مطلق خطا: $MAE = 2729.50$

کاهش چشمگیر خطای مدل پایه به واسطه تولید و تحلیل صریح فیچر تعاملی BMI * Smoker [9].

فاز دوم: طراحی و پیاده‌سازی شبکه‌های عصبی MLP

توسعه شبکه‌های عمیق با ساختار هرمی جهت مدل‌سازی الگوهای پنهان غیرخطی داده‌های عددی بیمه [9].

معماری پایه: MLP (64-32)

$$R^2 = 0.7937$$

$$RMSE = 5658.85$$

$$MAE = 4074.58$$

شبکه پنهان با دو لایه میانی با عرض کم. قادر به مدل‌سازی الگوهای سطحی است ولی فاقد عمق کافی برای استخراج الگوهای غیرخطی عمیق است [11].

معماری متوسط: MLP (128-64-32)

$$R^2 = 0.8596$$

$$RMSE = 4668.70$$

$$MAE = 2882.57$$

طراحی هرمی سه لایه. بهبود محسوسی در درک غیرخطی‌ها نشان می‌دهد و نسبت به مدل‌های کلاسیک خطی عملکرد پایدارتری دارد [11].

بهترین ساختار: MLP (256-128-64-32)

$$R^2 = 0.8696$$

$$RMSE = 4499.16$$

$$MAE = 2545.79$$

معماری هرمی عمیق ۴ لایه‌ای. به تدریج ویژگی‌های انتزاعی را فشرده می‌کند. این معماری بالاترین دقت پیش‌بینی را میان کل مدل‌ها ثبت کرد [11].

✓ پیکربندی بهینه آموزش: تابع فعال‌ساز ReLU، بهینه‌ساز Adam و استفاده از Early Stopping روی ۱۰٪ داده‌های آموزش (ولیدیشن) جهت توقف به‌موقع و پیشگیری از بیش‌برازش [10, 11].

فاز سوم: ساختار ریاضی ۵ لایه سیستم ANFIS

پیاده‌سازی گام به گام و خطبه‌خط ساختار ریاضی مدل Sugeno بر اساس مقاله Jang (1993) با NumPy خام. [11, 14]

۱. فازی‌سازی Fuzzification

محاسبه درجه عضویت ورودی‌ها با توابع عضویت گوسی مراکز (C) و انحراف معیار (σ) پارامترهای این لایه هستند. [12, 13]

۲. قدرت قوانین Rule Fire Strength

استفاده از عملگر ضرب (T-Norm) برای محاسبه همزمان قدرت شلیک قوانین بر اساس خروجی‌های لایه قبل. [13]

۳. نرمال‌سازی Normalization

محاسبه سهم شلیک هر قانون نسبت به جمع کل قدرت تمامی قوانین برای نرمال‌سازی [13, 14]


۴. نتیجه قوانین Consequent

ضرب وزن نرمال‌یافته در یک معادله خطی مرتبه اول از متغیرهای ورودی تابع درجه [13]

۵. تجمیع خروجی Aggregation

تجمیع نتایج لایه قبل جهت تولید مقدار عددی پیوسته و نهایی حق بیمه درمان [14].

ANFIS Learning Curve



الگوریتم یادگیری هیبریدی: کمترین مربعات خطا و گرادیان کاهشی

مسیر رفت: حل صریح و بهینه پارامترهای خطی

● ضرورت تفکیک یادگیری هیبریدی (Hybrid Learning):

به روزرسانی همزمان پارامترهای غیرخطی لایه اول و پارامترهای خطی لایه چهارم با گرادیان کاهشی معمولی منجر به ناپایداری شدید آموزش می‌شود. [17]

● بهینه‌سازی دقیق با مسیر رفت (Forward Pass):

در مسیر رفت، پارامترهای غیرخطی لایه اول فیکس نگه داشته می‌شوند. سپس پارامترهای خطی لایه چهارم (ضرایب Sugeno یعنی p , q , r) از حل صریح و مستقیم کمترین مربعات خطا (SE - Least Squares Estimation) با استفاده از تابع `np.linalg.lstsq` در محیط NumPy استخراج و بهینه‌سازی سراسری می‌شوند. [17, 18]

مسیر برگشت: به‌روزرسانی پارامترهای غیرخطی لایه اول

● به‌روزرسانی پارامترهای غیرخطی پیش‌فرض (Premise):

پس از فیکس شدن لایه چهارم در مسیر رفت، خطای محاسبه‌شده خروجی در مسیر برگشت (Backward Pass) به سمت لایه‌های عقب انتشار داده می‌شود. [17]

● بهینه‌سازی با گرادیان کاهشی (Gradient Descent):

پارامترهای غیرخطی توابع عضویت گوسی شامل مراکز (c) و انحراف استاندارد (σ) به وسیله گرادیان کاهشی با استفاده از فرمولاسیون مشتق زنجیره‌ای ماتریسی ارائه‌شده در کد پروژه بازنویسی و آپدیت می‌شوند [18, 19]

فاز سوم: مدیریت چالش نفرین ابعاد در سیستم فازی

بخش‌بندی شبکه‌ای و چالش انفجار قوانین فازی

● چالش ریاضی نفرین ابعاد (Curse of Dimensionality):

در فازی‌سازی کلاسیک با متد بخش‌بندی شبکه‌ای (Grid Partitioning)، قوانین حاصل ضرب حالت‌های توابع عضویت ورودی‌ها هستند. [20]

● فاجعه بیش‌برازش (Overfitting):

اگر تمامی ۱۲ ویژگی دموگرافیک دیتاست بیمه با تنها ۲ تابع عضویت فازی وارد سیستم می‌شدند، تعداد قوانین فازی معادل $2^{12} = 4096$ قانون می‌گردید. پیاده‌سازی این تعداد قانون برای ۱۳۳۸ سطر کل داده‌ها فاجعه همگرا شدن کاذب و Overfitting مطلق را پدید می‌آورد. [20]

راهکار مهندسی: گزینش ویژگی‌ها و تحلیل پایداری

● غربال‌گری ورودی‌ها با Feature Selection:


۳ متغیر کلیدی اصلی شامل سن (Age)، شاخص توده بدنی (BMI) و وضعیت دخیانیات (Smoker) استخراج و به عنوان تغذیه اصلی مدل فازی لحاظ شدند. [20]

● طراحی حلقه خودکار سنجش قوانین فازی:

برای سنجش دقیق رفتار ANFIS و کنترل چالش ابعاد، حلقه خودکاری برای مقایسه پایداری مدل در قالب ۳ سناریوی ۲ قانون، ۴ قانون و ۸ قانون فازی طراحی و عملکرد خطا در هر سناریو به صورت تجربی پایش شد. [20]

ارزیابی جامع و مقایسه عملکرد نهایی مدل‌ها

مدل پیاده‌سازی شده	R ² Score	RMSE (\$)	MAE (\$)
MLP (256-128-64-32)	0.8696	4499.16	2545.79
Polynomial Reg (d=2)	0.8666	4551.13	2729.50
MLP (128-64-32)	0.8596	4668.70	2882.57
MLP (64-32)	0.7937	5658.85	4074.58
Linear Regression	0.7836	5796.28	4181.19
ANFIS (8 rules)	0.7528	6194.96	4676.71
ANFIS (4 rules)	0.7528	6195.01	4676.74
ANFIS (2 rules)	0.7528	6195.01	4676.74



تحلیل نهایی، پدیده اشباع قوانین و اصل تیغ اوکام

تحلیل اشباع قوانین و اصل تیغ اوکام

● پدیده اشباع قوانین (Rule Saturation):

در بهینه‌سازی ANFIS مشاهده شد که افزایش قوانین فازی از ۴ به ۸ نه تنها خطای مدل را کاهش نداد، بلکه به دلیل پیچیدگی کاذب و انطباق افراطی بر سطرها، افت اندکی در ضریب تبیین ایجاد شد. [23]

● تکیه بر اصل علمی تیغ اوکام (Occam's Razor):

سادگی مدل یک ویژگی اساسی است. یک سیستم فازی با تنها ۴ قاعده فازی موفق شد به بالاترین توازن پایداری برسد. همچنین ساختار فازی با قابلیت تعریف زبانی قوانین، پیش‌بینی‌ها را برای متخصصان درمانی و کارشناسان بیمه به طور کامل ملموس و تبیین‌پذیر می‌سازد. [23]

توجیه ریاضی برتری رگرسیون چندجمله‌ای

● برابری کارایی چندجمله‌ای درجه ۲ با MLP:

این واقعیت که یک رگرسیون درجه ۲ آماری با $R^2 = 0.8666$ شانه به شانه شبکه عصبی عمیق با $R^2 = 0.8696$ حرکت می‌کند، اثبات می‌کند که ماهیت اصلی ساختار داده‌ها بر پایه تعامل مستقیم BMI * Smoker استوار است. [23]

● دستاورد مهندسی و ارزش هیبریدی نهایی:

این پروژه با موفقیت اثبات کرد که پیاده‌سازی همزمان رویکردهای آماری، عصبی عمیق و فازی-عصبی، ابعاد متمایزی از مسئله را روشن می‌سازد. موازنه بین تفسیرپذیری فوق‌العاده قواعد فازی و توان محاسباتی عمیق شبکه‌های عصبی، آینده توسعه سیستم‌های پیش‌بین بالینی است. [23, 24]

تشکر از توجه شما